```
In [ ]:
#naver news crawling
from bs4 import BeautifulSoup
import urllib.request
In [ ]:
import numpy as np
import pandas as pd
In [ ]:
# URL 주소 [정치]
URL1 = np.array([])
for i in np.arange(100):
  num = 3053599 - i
  new_URL = np.array(['https://news.naver.com/main/read.nhn?
mode=LSD&mid=shm&sid1=100&oid=081&aid=000{}'.format(num)])
 URL1 = np.concatenate((URL1, new_URL))
# URL 주소 [경제]
URL2 = np.array([])
for i in np.arange(100):
 num = 2962982 - i
 new URL = np.array(['https://news.naver.com/main/read.nhn?
mode=LSD&mid=shm&sid1=101&oid=025&aid=000{}'.format(num)])
 URL2 = np.concatenate((URL2, new URL))
# URL 주소 [사회]
URL3 = np.array([])
for i in np.arange(100):
  num = 7876 - i
  new URL = np.array(['https://news.naver.com/main/read.nhn?
mode=LSD&mid=shm&sid1=102&oid=629&aid=000000{}'.format(num)])
 URL3 = np.concatenate((URL3, new URL))
# URL 주소 [문화]
URL4 = np.array([])
for i in np.arange(100):
 num = 4542990 - i
 new_URL = np.array(['https://news.naver.com/main/read.nhn?
mode=LSD&mid=shm&sid1=103&oid=018&aid=000{}'.format(num)])
 URL4 = np.concatenate((URL4, new URL))
URL = np.array([URL1, URL2, URL3, URL4])
# 12/25 01:30 AM 기준
In [ ]:
URL1[0]
Out[]:
'https://news.naver.com/main/read.nhn?mode=LSD&mid=shm&sid1=100&oid=081&aid=0003053599'
In [ ]:
# 크롤링 함수
def get text(URL):
    source code from URL = urllib.request.urlopen(URL)
    soup = BeautifulSoup(source code from URL, 'lxml', from encoding='utf-8')
    text = ''
    for item in soup.find_all('div', id='articleBodyContents'):
       text = text + str(item.find all(text=True))
    return text
In [ ]:
```

```
# 데이터 클리닝 함수
import re
#클린 함수 (영어 및 특수 기호 제거)
def clean(before):
 after = re.sub('[a-zA-Z]', '', before)
  return after
In [ ]:
#데이터 프래임으로 만들기
import pandas as pd
genre = ['정치','경제','사회','문화']
text = np.array([])
category = np.array([])
for i in np.arange(4):
 for j in np.arange(100):
   cat = np.array([genre[i]])
   category = np.concatenate((category, cat))
   news = np.array([clean(get_text(URL[i][j]))])
   text = np.concatenate((text, news))
data0 = pd.DataFrame(np.array([text, category]), index=['text','category'])
data0 = data0.T
In [ ]:
from google.colab import drive
drive.mount('/content/drive')
Drive already mounted at /content/drive; to attempt to forcibly remount, call
drive.mount("/content/drive", force_remount=True).
In [ ]:
%pwd
Out[]:
'/content/drive/My Drive'
In [ ]:
%cd /content/drive/My Drive
/content/drive/My Drive
In [ ]:
  # csv 파일로 저장
 data0.to csv("data0.csv")
In [ ]:
 #csv 파일 불러오기
 data0 = pd.read_csv('data0.csv')
In [ ]:
data0 = data0.loc[:,['text','category']]
data0
Out[]:
```

0	중국 청두서 文아베 한일 정상회담 서울신문 개월 만 帥x f.	category
1	시니어 헬스케어 로봇과 챗봇 공동연구 서울신문 가천대와	정치
2	서울신문 일 경기 용인시 기흥구의 한 단독주택에서 불이나	정치
3	서울신문 성탄절 맞아 어린이 환자들에게 선물하는 김정숙	정치
4	서울신문 손석희 대표이사 사장뉴스 손석희 대표이사 사	정치
395	국민은행 노조위원장 시절 파업 주도 임명강행시 여당과	문화
396	이데일리 김대웅 기자 넥스트사이언스는 자회사 엘리샤코이가	문화
397	이데일리 현재 코스닥 외국인 억 순매도 마켓포인트	문화
398	이데일리 현재 코스닥 개인 억 순매도 마켓포인트 네	문화
399	이데일리 현재 코스닥 기관 억 순매수 마켓포인트 네	문화

400 rows × 2 columns

In []:

data0

Out[]:

	text	category
0	중국 청두서 文아베 한일 정상회담 서울신문 개월 만에	정치
1	시니어 헬스케어 로봇과 챗봇 공동연구 서울신문 가천대와	정치
2	서울신문 일 경기 용인시 기흥구의 한 단독주택에서 불이나	정치
3	서울신문 성탄절 맞아 어린이 환자들에게 선물하는 김정숙	정치
4	서울신문 손석희 대표이사 사장뉴스 손석희 대표이사 사	정치
395	국민은행 노조위원장 시절 파업 주도 임명강행시 여당과	문화
396	이데일리 김대웅 기자 넥스트사이언스는 자회사 엘리샤코이가	문화
397	이데일리 현재 코스닥 외국인 억 순매도 마켓포인트	문화
398	이데일리 현재 코스닥 개인 억 순매도 마켓포인트 네	문화
399	이데일리 현재 코스닥 기관 억 순매수 마켓포인트 네	문화

400 rows × 2 columns

In []:

```
# target에 숫자로 label 부여

from sklearn.preprocessing import LabelEncoder
labeling = LabelEncoder()
y = labeling.fit_transform(data0['category'].values)
y
```

Out[]:

```
3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
```

```
1, 1, 1, 1])
In [ ]:
# 결측값 대체
# text가 결측일 경우 전 기사의 text 가져오기
for i in np.arange(400):
  if str(data0['text'][i]) == 'nan':
    data0['text'][i] = data0['text'][i-1]
data0['text'].head(10)
Out[]:
0
                       중국 청두서 文아베 한일 정상회담 서울신문 개월 만에 ...
                       시니어 헬스케어 로봇과 챗봇 공동연구 서울신문 가천대와...
                      서울신문 일 경기 용인시 기흥구의 한 단독주택에서 불이나...
                      서울신문 성탄절 맞아 어린이 환자들에게 선물하는 김정숙 ...
.3
                      서울신문 손석희 대표이사 사장뉴스 손석희 대표이사 사...
                       '여성 호 치안정감' 이은정 경찰대학장 서울신문 남성영...
                      서울신문 문재인 대통령과 아베 일본 총리가 일현지시간 중...
                      서울신문 문재인 대통령과 아베 일본 총리가 일현지시간 중...
                                             오류를 우회하기 위한 함수 추가...
       본문 내용
                                 플레이어
                    플레이어
8
       본문 내용
                    플레이어
                                 플레이어
                                             오류를 우회하기 위한 함수 추가...
Name: text, dtype: object
In [ ]:
# 추가 데이터 정제
def addclean(text):
  text = re.sub('[0-9]','',text)
  text = re.sub('\b','',text)
  text = re.sub('""','"',text)
  text = re.sub('\Delta', '', text)
  text = re.sub('♦','',text)
  text = re.sub('©', '', text)
  text = re.sub('\s본문','', text)
  text = re.sub('\s내용','', text)
  text = re.sub('\s오류를','', text)
  text = re.sub('\s플레이어','', text)
  text = re.sub('\s<mark>함수','',</mark> text)
  text = re.sub('\s<mark>우회하기','', text</mark>)
  text = re.sub('\s함수','',text)
  text = re.sub('\s위한','', text)
  text = re.sub('\s추가','', text)
  return text.
for i in np.arange(400):
  data0['text'][i] = addclean(data0['text'][i])
# feature variable X 생성
X = data0['text'].values
In [ ]:
# 문장 vector화 하는 vectorizer
from sklearn.feature_extraction.text import TfidfVectorizer
vectorizer = TfidfVectorizer()
text = [data0['text'][7]]
voc = vectorizer.fit transform(text)
print(vectorizer.get_feature_names())
print(voc.shape)
['가까운', '가장', '갈등', '강조했다', '같이', '걸어가야', '것이', '계속', '계정에', '공유하는', '과거의', '구독하기', '국가들과', '국은', '귀국길에', '그러나', '글을', '기자', '긴밀히', '나가야', '나라든', '네이버에서', '대통령과', '대통령은', '동안의', '때때로', '떠나며', '라는', '마치고', '모두', '무단전재', '무료만화', '문재인', '문화를', '미래지향적인', '발전시켜', '발전해', '밝혔다', '방중', '보기', '분명히', '불거지는', '불했하', '사는', '샹그릴라호텔에서', '서울신문', '세기성', '세상에', '소셜네트워크서비스', '속에서', '수천', '쓰
```

 천성', '아베', '악수하고', '앞서', '어느', '어울려', '언급했다', '없다', '역사로', '역사로', '역사와', '연합뉴스', '오랜', '오른', '올려', '요소가', '우리가', '우리는', '이날', '이라고', '이라며', '이라면서', '이런', '이렇게', '이웃', '인해', '일본', '일이', '일정을', '일현지시간', '있다', '자신의', '재배포금지', '정상회담에', '제목의', '중국', '직시하면서도', '청두', '청두를', '총리가', '최선을', '클릭', '하고', '한다', '한중일', '함께', '협력', '협력을', '협력해야', '홀로']

In []:

```
# 장르 별 최빈단어 10개씩 찾기

vocabl = np.array([])

for i in np.arange(100):
    text = np.array([X[i]])
    new_vocab = vectorizer.fit_transform(text)
    vocabl = np.concatenate((vocabl, vectorizer.get_feature_names()))
```

Out[]:

18176

In []:

```
# train, test set 나누기

from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, stratify=y)
```

In []:

```
# 단어를 분할하는 tokenizer - 안써도 될듯
def tokenizer(text):
    return text.split()
```

In []:

In []:

```
print(gs_lr_tfidf.best_params_)

y_train_predl = gs_lr_tfidf.predict(X_train)

y_test_predl = gs_lr_tfidf.predict(X_test)

from sklearn.metrics import accuracy_score

print(accuracy_score(y_train, y_train_predl)) # train data에 대한 accuracy

print(accuracy_score(y_test, y_test_predl)) # test data에 대한 accuracy
```

```
In [ ]:
# 분류 결과 logistic
from sklearn.metrics import confusion matrix
print(confusion matrix(y test, y test pred1))
[[30 0 0 0]
 [ 0 30 0 0]
 [ 0 0 30 0]
 [ 0 0 0 30]]
In [ ]:
#KNN
from sklearn.model_selection import GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.neighbors import KNeighborsClassifier
\texttt{tfidf} = \texttt{TfidfVectorizer(strip\_accents} = \textbf{None}, \texttt{lowercase} = \textbf{False}, \texttt{preprocessor} = \textbf{None})
param_grid = [{'vect__ngram_range': [(1,1)],'vect__tokenizer': [tokenizer,None],'knn__n_neighbors'
:[3,5,10], 'knn p': [1,2]},
                {'vect ngram range': [(1,1)],'vect tokenizer': [tokenizer, None],'vect use idf':[
False],
                 'vect norm': [None], 'knn n neighbors': [3,5,10], 'knn p': [1,2]}]
knn_tfidf = Pipeline([('vect', tfidf),('knn', KNeighborsClassifier())])
gs knn tfidf = GridSearchCV(knn tfidf, param grid,scoring='accuracy',cv=5, verbose=1,n jobs=1)
gs knn tfidf.fit(X train, y train)
                                                                                                   )
Fitting 5 folds for each of 24 candidates, totalling 120 fits
[Parallel(n jobs=1)]: Using backend SequentialBackend with 1 concurrent workers.
[Parallel(n jobs=1)]: Done 120 out of 120 | elapsed: 14.4s finished
Out[]:
GridSearchCV(cv=5, error score='raise-deprecating',
              estimator=Pipeline (memory=None,
                                  steps=[('vect',
                                           TfidfVectorizer(analyzer='word',
                                                            binary=False,
                                                            decode_error='strict',
                                                            dtype=<class 'numpy.float64'>,
                                                            encoding='utf-8',
                                                            input='content',
                                                            lowercase=False,
                                                            \max df=1.0,
                                                            max features=None,
                                                            min df=1,
                                                            ngram range=(1, 1),
                                                            norm='12',
                                                            preprocessor=None,
                                                            smooth idf=True,
                                                            stop_word...
                            'vect ngram_range': [(1, 1)],
                            'vect tokenizer': [<function tokenizer at 0x7faa73d44620>,
                                                 None]},
                           {'knn__n_neighbors': [3, 5, 10], 'knn__p': [1, 2],
'vect__ngram_range': [(1, 1)], 'vect__norm': [None],
                            'vect tokenizer': [<function tokenizer at 0x7faa73d44620>,
                                                 Nonel.
                            'vect use idf': [False]}],
              pre dispatch='2*n jobs', refit=True, return train score=False,
              scoring='accuracy', verbose=1)
In [ ]:
print(gs knn tfidf.best params )
```

v train nred? = as knn tfidf nredict(Y train)

```
y crain preuz - yo kim criar.preutoc(k crain)
y_test_pred2 = gs_knn_tfidf.predict(X_test)
from sklearn.metrics import accuracy_score
print(accuracy_score(y_train, y_train_pred2)) # train data에 대한 accuracy
print(accuracy_score(y_test, y_test_pred2)) # test data에 대한 accuracy
{'rf__max_depth': 3, 'rf__n_estimators': 50, 'vect__ngram_range': (1, 1), 'vect__tokenizer': <func</pre>
tion tokenizer at 0x7faa73d44620>}
0.9
0.8
In [ ]:
# 분류 결과 KNN
from sklearn.metrics import confusion_matrix
print(confusion matrix(y test, y test pred2))
[[17 1 6 6]
 [ 0 27 0 3]
 [ 1 1 26 2]
 [ 0 2 2 26]]
In [ ]:
#SVM
from sklearn.model selection import GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.svm import SVC
tfidf = TfidfVectorizer(strip accents=None,lowercase=False,preprocessor=None)
param grid = [{'vect ngram range': [(1,1)],'vect tokenizer': [tokenizer,None],'svc C':[1e3,5e3,1
e4,5e4,1e5],
               'svc gamma': [0.005,0.01,0.1], 'svc_kernel':['poly','rbf','sigmoid']},
               {'vect ngram range': [(1,1)],'vect tokenizer': [tokenizer, None],'vect use idf':[
Falsel.
                'vect norm': [None], 'svc C': [1e3,5e3,1e4,5e4,1e5],
               'svc_gamma': [0.005,0.01,0.1], 'svc_kernel':['poly','rbf','sigmoid']}]
svc tfidf = Pipeline([('vect', tfidf),('svc', SVC())])
gs svc tfidf = GridSearchCV(svc tfidf, param grid,scoring='accuracy',cv=5, verbose=1,n jobs=1)
gs svc tfidf.fit(X train, y train)
4
                                                                                                | b
Fitting 5 folds for each of 180 candidates, totalling 900 fits
[Parallel(n jobs=1)]: Using backend SequentialBackend with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done 900 out of 900 | elapsed: 2.8min finished
Out[]:
GridSearchCV(cv=5, error score='raise-deprecating',
             estimator=Pipeline (memory=None,
                                steps=[('vect',
                                        TfidfVectorizer(analyzer='word',
                                                        binary=False,
                                                        decode error='strict',
                                                        dtype=<class 'numpy.float64'>,
                                                        encoding='utf-8',
                                                        input='content',
                                                        lowercase=False,
                                                        \max df=1.0,
                                                        max features=None,
                                                        min_df=1,
                                                        ngram range=(1, 1),
                                                        norm='12',
                                                        preprocessor=None,
                                                        smooth idf=True,
                                                        stop_word...
                                              None]},
                         {'svc C': [1000.0, 5000.0, 10000.0, 50000.0,
                                     100000.0],
                          'svc gamma': [0.005. 0.01. 0.1].
```

```
'svc_kernel': ['poly', 'rbf', 'sigmoid'],
                          'vect__ngram_range': [(1, 1)], 'vect__norm': [None],
                          'vect_tokenizer': [<function tokenizer at 0x7faa73d44620>,
                                              None],
                          'vect__use_idf': [False]}],
             pre dispatch='2*n jobs', refit=True, return_train_score=False,
             scoring='accuracy', verbose=1)
In [ ]:
print(gs svc tfidf.best params )
y_train_pred3 = gs_svc_tfidf.predict(X_train)
y test pred3 = gs svc tfidf.predict(X test)
from sklearn.metrics import accuracy score
print(accuracy score(y train, y train pred3)) # train data에 대한 accuracy
print(accuracy_score(y_test, y_test_pred3)) # test data에 대한 accuracy
{'svc C': 1000.0, 'svc gamma': 0.005, 'svc kernel': 'rbf', 'vect ngram range': (1, 1),
'vect tokenizer': None}
1.0
0.95
In [ ]:
# 분류 결과 SVC
from sklearn.metrics import confusion matrix
print(confusion_matrix(y_test, y_test_pred3))
[ 1 0 28 1]
 [ 0 2 0 28]]
In [ ]:
#Random Forest
from sklearn.model_selection import GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.ensemble import RandomForestClassifier
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.ensemble import RandomForestClassifier
tfidf = TfidfVectorizer(strip_accents=None,lowercase=False,preprocessor=None)
param_grid = [{'vect__ngram_range': [(1,1)],'vect__tokenizer': [tokenizer,None],
               'rf n estimators':[50,100,200,500],'rf max depth': [3,5,10]},
               {'vect__ngram_range': [(1,1)],'vect__tokenizer': [tokenizer, None],'vect__use_idf':[
False],
                'vect__norm':[None],'rf__n_estimators':[50,100,200,500],'rf__max_depth': [3,5,10]}]
rf_tfidf = Pipeline([('vect', tfidf),('rf', RandomForestClassifier())])
gs rf tfidf = GridSearchCV(rf tfidf, param grid,scoring='accuracy',cv=5, verbose=1,n jobs=1)
gs rf tfidf.fit(X train, y train)
4
Fitting 5 folds for each of 48 candidates, totalling 240 fits
[Parallel(n jobs=1)]: Using backend SequentialBackend with 1 concurrent workers.
[Parallel(n jobs=1)]: Done 240 out of 240 | elapsed: 1.5min finished
Out[]:
GridSearchCV(cv=5, error score='raise-deprecating',
             estimator=Pipeline (memory=None,
                               steps=[('vect',
                                        TfidfVectorizer(analyzer='word',
                                                        binary=False,
                                                        decode error='strict',
                                                        dtype=<class 'numpy.float64'>,
                                                        encoding='utf-8',
                                                        input='content',
```

```
lowercase=False,
                                                        \max_{df=1.0,}
                                                        max features=None,
                                                        min df=1,
                                                        ngram range=(1, 1),
                                                        norm='12',
                                                        preprocessor=None,
                                                        smooth idf=True,
                                                        stop word...
                          'vect ngram range': [(1, 1)],
                          'vect tokenizer': [<function tokenizer at 0x7faa73d44620>,
                                             None]},
                         {'rf__max_depth': [3, 5, 10],
                          'rf__n_estimators': [50, 100, 200, 500],
                          'vect__ngram_range': [(1, 1)], 'vect__norm': [None],
                          'vect_tokenizer': [<function tokenizer at 0x7faa73d44620>,
                          'vect__use_idf': [False]}],
             pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
             scoring='accuracy', verbose=1)
In [ ]:
print(gs rf tfidf.best params )
y train pred4 = gs rf tfidf.predict(X train)
y_test_pred4 = gs_rf_tfidf.predict(X_test)
from sklearn.metrics import accuracy_score
print(accuracy_score(y_train, y_train_pred4)) # train data에 대한 accuracy
print(accuracy_score(y_test, y_test_pred4)) # test data에 대한 accuracy
{'rf max depth': 3, 'rf n estimators': 50, 'vect ngram range': (1, 1), 'vect tokenizer': <func
tion tokenizer at 0x7faa73d44620>}
1.0
1.0
In [ ]:
# 분류 결과 RandomForest
from sklearn.metrics import confusion_matrix
print(confusion_matrix(y_test, y_test_pred4))
[[30 0 0 0]
[ 0 30 0 0]
 [ 0 0 30 0]
 [ 0 0 0 30]]
```